
SignMuon: fast as Muon, communication-effective as SignSGD

Maria Smirnova
MIPT
Moscow, Russia
smirnova.ma@phystech.edu

Alexey Kravatskiy
MIPT
Moscow, Russia
email@phystech.edu

Dmitry Kovalev
MIPT
Moscow, Russia
email@phystech.edu

Abstract

SignSGD is a popular algorithm due to its strong performance in both centralized and decentralized settings: it performs competitively with Adam while being communication-efficient, transmitting up to 32x fewer bits than standard optimizers. This work introduces SignMuon, an algorithm that combines the structured LMO-based update of Muon with the sign compression of SignSGD. Our experiments show that SignMuon achieves performance nearly on par with Muon in the centralized setting and outperforms SignSGD in both centralized and federated settings. We establish theoretical convergence guarantees for SignMuon in the smooth non-convex regime. We further analyze specific modifications to the algorithm that enhance numerical stability without compromising communication efficiency. Finally, this work extends our framework to the broader class of SignA algorithms, where A denotes any LMO-based optimizer, providing a unified convergence analysis for sign-compressed LMO methods. Empirical validation is conducted on synthetic convex and nonconvex problems with known smoothness constants, CIFAR-airbench, federated MNIST/CIFAR-10 classification, and NanoGPT training.

Keywords: TODO

1 Введение (Introduction)

Современные методы обучения глубоких нейронных сетей (DNN) требуют использования оптимизаторов, которые не только обеспечивают высокую скорость сходимости, но и минимизируют коммуникационные издержки в распределённых и федеративных системах, где передача обновлений между узлами является узким местом (bottleneck). Так, алгоритм SignSGD продемонстрировал, что даже экстремальная компрессия (до 1 бита на компоненту) сохраняет работоспособность метода и позволяет сократить объём передаваемых данных примерно в 32 раза при незначительной потере качества модели [1, 2].

SignSGD плохо учитывает матричную структуру параметров: в задачах с матричными весами он рассматривает матрицы как одномерные векторы (flattening), игнорируя их внутреннюю 2D-тензорную структуру, что может ухудшать качество обучения DNN. Недавно предложенный оптимизатор Muon показал, что его ортонормированные обновления стабилизируют обучение DNN и в ряде случаев превосходят стандартные адаптивные методы оптимизации по качеству итогового решения [3–5].

Однако Muon требует передачи полных матриц обновлений, что в федеративных задачах может быть слишком затратным. В условиях федеративного обучения данные распределены между узлами, которые обмениваются параметрами с сервером с целью обучения общей модели. Каждый узел имеет локальный набор данных, а целью федеративного машинного обучения является минимизация усредненной функции потерь по всем узлам. Поскольку участники

сети часто находятся на значительном расстоянии от агрегирующего сервера и могут иметь ограниченную пропускную способность канала связи, возникает коммуникационное узкое место. Для решения этой проблемы обычно используются методы компрессии градиентов и обновлений [1, 6–8].

В данной работе мы предлагаем алгоритм SignMuon, который объединяет методы обновления Muon с экстремальной компрессией SignSGD. В отличие от SignSGD, где передаётся знак стохастического градиента, наш метод сначала вычисляет направление спуска с помощью LMO-обновления, аналогично Muon, а затем передаёт только знак этого направления. Такая схема позволяет учитывать матричную структуру параметров и сохранять преимущества Muon, одновременно сокращая объём передаваемой информации до одного бита на компоненту. Тем самым SignMuon стремится объединить быструю сходимость структурированных оптимизаторов с коммуникационной эффективностью знаковых методов.

Эффективность предложенного оптимизатора показана на различных синтетических и прикладных задачах:

- Синтетический эксперимент по методу наименьших квадратов;
- Бенчмарк CIFAR-10 airbench [9]
- Классификация изображений MNIST
- Предварительное обучение (pre-training) моделей NanoGPT и GPT-2 Medium на датасете FineWeb [10]

Наши эксперименты направлены на изучение того, насколько эффективно можно сочетать структурированные направления обновления Muon с экстремальной коммуникационной компрессией знаковых методов. В частности, мы анализируем, как передача только знака направления обновления влияет на качество и устойчивость обучения по сравнению с использованием полного Muon-обновления.

Экспериментальные результаты показывают, что использование знаковой компрессии для направлений Muon позволяет (to be continued...)

Таким образом, предложенный подход демонстрирует, что LMO-основанные методы могут быть успешно объединены с знаковой компрессией без существенной потери качества обучения. Более того, предложенная схема естественным образом обобщается на более широкий класс алгоритмов SignA, где A обозначает любой оптимизатор, использующий LMO-направления. Это открывает возможность построения новых коммуникационно-эффективных алгоритмов оптимизации.

2 Постановка задачи (Problem Statement)

Рассматриваем стохастическую задачу оптимизации для гладкой невыпуклой функции

$$\min_{\mathbf{x} \in \mathbb{R}^d} f(\mathbf{x}) = \mathbb{E}_{\xi \sim \mathcal{J}} [f(\mathbf{x}, \xi)], \quad (1)$$

где ξ — случайный вектор неизвестного распределения $\mathcal{J}$, $f(\mathbf{x}, \xi)$ — функция потерь модели (loss function). В контексте обучения DNN: $\mathbf{x} \in \mathbb{R}^d$ — вектор всех параметров, цель практической оптимизации — найти точку $\mathbf{x}$ с малой нормой градиента $\|\nabla f(\mathbf{x})\|$.

Рассмотрим данную задачу в контексте федеративного обучения. Пусть данные распределены по M узлам, каждый узел m имеет локальную выборку D_m размера $|D_m|$ и соответствующую локальную функцию потерь $f_m(\mathbf{x}) = \mathbb{E}_{\xi \sim D_m} [f(\mathbf{x}, \xi)]$. Цель — минимизировать усреднённую по всем узлам функцию:

$$F(\mathbf{x}) = \min_{\mathbf{x} \in \mathbb{R}^d} \frac{1}{M} \sum_{m=1}^M \mathbb{E}_{\xi_m \sim D_m} f(\mathbf{x}, \xi_m), \quad \min_{\mathbf{x} \in \mathbb{R}^d} F(\mathbf{x}). \quad (2)$$

В федеративном режиме узлы вычисляют локальные стохастические градиенты и периодически отправляют сообщения на сервер, канал коммуникации часто ограничен, поэтому критическим ресурсом является объём передаваемых данных [2, 6]. Для обзора практических приёмов в федеративном обучении и компрессии см. также [7, 11, 12].

Возможные ограничения связаны с L -гладкостью функции f в неевклидовом пространстве, оснащённом нормой $\|\cdot\| : \|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\|_* \leq L\|\mathbf{x} - \mathbf{y}\|$, где $\|\cdot\|_*$ — дуальная норма. На практике возможно использовать ослабленные условия типа (L_0, L_1) [13]. Учитывая результаты существующих исследований, показавших неэффективность передачи полных 32-битных градиентов в распределённых системах, целесообразно рассмотреть сценарии с экстремальной компрессией, где целевой уровень сжатия составляет 1 бит на компоненту сообщения [1, 2, 7].

Определим Linear Minimization Oracle (LMO) - оператор $A(\cdot)$ как решение задачи линейной минимизации на допустимом множестве:

$$A(\mathbf{G}) = \arg \min_{\mathbf{D} \in \mathcal{S}} \langle \mathbf{G}, \mathbf{D} \rangle. \quad (3)$$

где $\mathbf{G} \in \mathbb{R}^{m \times n}$ — градиент (или его стохастическая оценка), $\mathbf{D} \in \mathbb{R}^{m \times n}$ — направление обновления, $\langle \mathbf{A}, \mathbf{B} \rangle = \text{tr}(\mathbf{A}^\top \mathbf{B})$ — стандартное скалярное произведение матриц, а $\mathcal{S} \subset \mathbb{R}^{m \times n}$ — множество допустимых направлений [14]. В частности, ограничения можно задать через единичный шар некоторой нормы:

$$A(\mathbf{G}) = \arg \min_{\|\mathbf{D}\| \leq 1} \langle \mathbf{G}, \mathbf{D} \rangle. \quad (4)$$

Такой оператор выбирает направление наискорейшего спуска в заданной норме. Аналитическая и практическая роль LMO подробно обсуждается в работах по норм-ограниченным LMO-оптимизаторам [14–16].

Оптимизатор Muon использует матричную структуру градиента. Пусть $\mathbf{G} = \mathbf{U}\Sigma\mathbf{V}^\top$ — сингулярное разложение матрицы $\mathbf{G} \in \mathbb{R}^{m \times n}$, где $\mathbf{U} \in \mathbb{R}^{m \times r}$, $\mathbf{V} \in \mathbb{R}^{n \times r}$ — ортонормированные матрицы сингулярных векторов, $\Sigma \in \mathbb{R}^{r \times r}$ — диагональная матрица сингулярных значений, $r = \text{rank}(\mathbf{G})$. Тогда LMO-направление имеет вид

$$A(\mathbf{G}) = \mathbf{U}\mathbf{V}^\top \in \mathbb{R}^{m \times n}. \quad (5)$$

то есть выбирается ортонормированное направление, соответствующее решению задачи линейной минимизации. Muon реализует шаг steepest descent в спектральной норме, где направление обновления получается ортогонализацией матрицы градиента. На практике Muon использует сглаженную оценку градиента с импульсом.

$$\begin{aligned} \mathbf{M}_t &= \mu \mathbf{M}_{t-1} + \mathbf{G}_t, \\ \mathbf{M}_t &= \mathbf{U}_t \Sigma_t \mathbf{V}_t^\top, \\ \mathbf{D}_t &= \mathbf{U}_t \mathbf{V}_t^\top. \end{aligned} \quad (6)$$

В исходной реализации Muon вычисление $\mathbf{U}_t \mathbf{V}_t^\top$ выполняется приближённо с помощью итераций Ньютона–Шульца и других полиномиальных схем, что позволяет эффективно ортогонализировать матрицу без явного вычисления SVD [17–19]. Интуитивно такая ортогонализация делает обновления изотропными и предотвращает доминирование нескольких направлений градиента, что особенно важно при обучении DNN [3, 5].

Обозначим компрессию через поэлементную знаковую функцию $\text{sign}(\mathbf{M}) \in \{\pm 1\}^d$, и определим класс алгоритмов SignA как:

$$\begin{aligned} A(\mathbf{G}_t) : \mathbf{G}_t &\rightarrow \mathbf{D}_t, \\ \mathbf{s}_t &= \text{sign}(\mathbf{D}_t), \\ \mathbf{X}_{t+1} &= \mathbf{X}_t - \eta_t \hat{\mathbf{s}}_t. \end{aligned} \quad (7)$$

где $\hat{\mathbf{s}}_t$ — агрегированное сообщение (в централизованной схеме $\hat{\mathbf{s}}_t = \mathbf{s}_t$, во федеративной — majority-vote или среднее по узлам). Частным случаем данного семейства алгоритмов является SignMuon, где A — Muon (т.е. $\mathbf{D}_t = \mathbf{U}_t \mathbf{V}_t^\top$) и передаётся $\text{sign}(\mathbf{U}_t \mathbf{V}_t^\top)$ [20].

SignA реализует шаг steepest-descent с ограничением по норме и LMO-направлением:

$$\mathbf{X}_{t+1} = \mathbf{X}_t - \eta_t \text{sign} \left(\arg \min_{\|\mathbf{D}\| \leq 1} \langle \mathbf{G}_t, \mathbf{D} \rangle \right). \quad (8)$$

Мы поставили цель сконструировать коммуникационно-эффективный метод, который обеспечивает теоретические и эмпирические гарантии сходимости, сравнимые с Muon по качеству и с SignSGD — по коммуникации:

$$\min_{t \leq T} \mathbb{E} \|\nabla f(\mathbf{x}_t)\|^2 = \mathcal{O}(T^{-1/2}), \quad (9)$$

при использовании коммуникационного бюджета порядка d бит на шаг (sign-кодирование). Для анализа модификаций с error-feedback и квантованием см. [11, 21].

3 Theory

TODO

4 Вычислительный эксперимент (Computational Experiment)

Целью эксперимента является эмпирическая валидация алгоритма SignMuon, как оптимизатора, объединяющего высокую скорость сходимости LMO-оптимизаторов с коммуникационной эффективностью знаковой компрессии. Само исследование состоит из нескольких частей:

- **Централизованное обучение (Centralized Performance):** Сравнение динамики сходимости и итоговой точности (Accuracy) алгоритма SignMuon с классическими оптимизаторами Adam, SGD, SignSGD и Muon при фиксированном количестве эпох. Одной из целей является демонстрация того, что SignMuon обеспечивает высокое качество классификации, сопоставимое с Muon, и при этом превосходит по точности классический знаковый метод SignSGD при идентичной коммуникации (1 бит на параметр).
- **Федеративное обучение (Federated learning):** Оценка алгоритма в распределенной среде, где передача полных 32-битных матриц градиентов является bottleneck. Цель данного этапа исследования показать, что сжатие ортогонализированных LMO-обновлений позволяет достичь качества полного Muon при снижении объема передаваемых данных.
- **Синтетическая неевклидова оптимизация (Synthetic Benchmarks):** Исследование сходимости расширенного семейства алгоритмов SignA на контролируемых задачах. Использование синтетических сред с заранее известными константами гладкости и числами обусловленности позволяет ... TODO
- **Эксперимент на масштабируемость и LLM:** Применение алгоритма SignMuon с целью предварительного обучения (pre-training) языковых моделей архитектуры Transformer. Валидация проводится на базе высокооптимизированного фреймворка Modded-NanoGPT, что позволяет сравнить SignMuon с Muon и AdamW. ... TODO

Наборы данных. Эксперименты проводятся на синтетических и реальных наборах данных:

- **CIFAR-10:** Стандартный датасет для задачи классификации изображений. Содержит 60 000 цветных изображений размера 3x32x32. Для централизованного обучения датасет делится на обучающую и тестовую выборку, для федеративного сценария обучающая выборка партиционируется между узлами.
- **MNIST:** Датасет для задачи классификации изображений, используемый в бенчмарках распределенного обучения. Содержит 70 000 черно-белых изображений рукописных цифр размера 1x28x28. Как и в случае с CIFAR-10, для централизованного обучения датасет делится на обучающую и тестовую выборки, а для федеративного сценария обучающая выборка партиционируется между узлами.
- **Синтетические данные:** TODO
- **FineWeb (для NanoGPT):** Текстовый корпус для pre-training языковых моделей, используемый в бенчмарках серии modded-nanogpt.

Конфигурация алгоритма. Для экспериментов на MNIST и CIFAR-10 используется 4-слойная сверточная архитектура (CNN). Оптимизация матричных параметров производится исследуемыми алгоритмами SignMuon, Muon, SignSGD, SGD, Adam. Векторные параметры (смещения) обновляются с помощью Adam [9]. В качестве метода ортогонализации для Muon и SignMuon используется алгоритм Ньютона-Шульца. Темп обучения (learning rate) варьируется в зависимости от примененного алгоритма, используется Nesterov Momentum (0.9) и пкосинусный планировщик скорости обучения (CosineAnnealingLR). Обновление шага обучения η_t на эпохе t осуществляется по следующей формуле:

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min}) \left(1 + \cos \left(\frac{t}{T_{\max}} \pi \right) \right), \quad (10)$$

где $\eta_{\max}$ — начальный темп обучения алгоритма, $\eta_{\min} = 0$ — минимальное значение (в нашей конфигурации), а $T_{\max}$ соответствует общему числу эпох обучения.

Ожидаемые таблицы и графики. После проведения исследований ожидаем получения следующих результатов: график сравнение сходимости, по оси X — количество эпох (epochs), Y — точность на тестовой выборке / значение функции потерь; таблица сравнения конечных результатов обучения; график сравнения коммуникационной эффективности в распределенном обучении.

5 Предварительные результаты (Preliminary Report)

В качестве базовой модели для централизованного обучения была реализована сверточная нейронная сеть, представляющая собой отображение из пространства изображений в пространство вероятностей классов. Архитектура сети включает два сверточных блока с пакетной нормализацией (BatchNorm) и MLP-классификатор (multilayer perceptron). Основным исследуемым алгоритмом является SignMuon. Практическая реализация алгоритма учитывает тензорную структуру параметров нейронной сети. Процесс оптимизации разделен на два потока[9]:

1. Матричные параметры (веса сверточных и полносвязных слоев, $ndim \geq 2$) обновляются с помощью LMO-оракула.
2. Векторные параметры (смещения и веса слоев пакетной нормализации, $ndim < 2$) оптимизируются стандартным методом Adam.

Первоначально такой подход был предложен Jordan и другими [4] в эмпирическом описании. Первый результат о теоретической сходимости был получен Li и Hong, которые проанализировали гладкую невыпуклую постановку [18]. Так же данный подход описан в работе Рябинина [16].

Вычисление ортонормированного направления $\mathbf{D}_t \approx \mathbf{U}_t \mathbf{V}_t^\top$ для матричных параметров осуществляется без явного вычисления сингулярного разложения (SVD). Вместо этого применяется итерационный алгоритм Ньютона–Шульца. После получения LMO-направления $\mathbf{D}_t$, к нему применяется поэлементная функция $\text{sign}(\mathbf{D}_t)$, что сокращает объем передаваемой информации до 1 бита на компоненту. Логика обновления представлена в Алгоритме 1:

Algorithm 1 Обновление матричных параметров алгоритмом SignMuon

Require: Текущие веса $\mathbf{X}_t$, градиент $\mathbf{G}_t$, импульс μ , шаг обучения η_t , буфер импульса $\mathbf{M}_{t-1}$


Ensure: Обновленные веса $\mathbf{X}_{t+1}$

```


1:  $\tilde{\mathbf{M}}_t \leftarrow \mu \mathbf{M}_{t-1} + \mathbf{G}_t$  ▷ Сглаженный градиент (импульс)
2:  $\tilde{\mathbf{M}}_t \leftarrow \mathbf{G}_t + \mu \tilde{\mathbf{M}}_t$  ▷ Шаг Нестерова для ускорения сходимости
3:  $\mathbf{Y} \leftarrow \text{ReshapeTo2D}(\tilde{\mathbf{M}}_t)$  ▷ Приведение тензора к матрице  $m \times n$ 
4:  $\mathbf{Y} \leftarrow \mathbf{Y} / (\|\mathbf{Y}\|_F + \varepsilon)$  ▷ Нормализация
5: for  $k = 1$  to 5 do ▷ Итерации Ньютона-Шульца для аппроксимации  $\text{sign}(\mathbf{Y})$ 
6:    $\mathbf{A} \leftarrow \mathbf{Y} \mathbf{Y}^\top$ 
7:    $\mathbf{Y} \leftarrow 3.4445 \mathbf{Y} - 4.7750 \mathbf{A} \mathbf{Y} + 2.0315 \mathbf{A}^2 \mathbf{Y}$ 
8: end for
9:  $\mathbf{D}_t \leftarrow \text{ReshapeToOriginal}(\mathbf{Y})$  ▷ Восстановление исходной размерности
10:  $\mathbf{s}_t \leftarrow \text{sign}(\mathbf{D}_t)$  ▷ Знаковая компрессия
11:  $\mathbf{X}_{t+1} \leftarrow \mathbf{X}_t - \eta_t \mathbf{s}_t$  ▷ Обновление весов
12: return  $\mathbf{X}_{t+1}$ 

```


На данном этапе реализован программный пайплайн и проведен базовый вычислительный эксперимент по централизованному обучению на наборах данных MNIST и CIFAR-10. На датасете CIFAR-10 модель обучалась в течение 50 эпох с использованием CosineAnnealingLR. Для валидации предложенного алгоритма SignMuon проводилось сравнение с оптимизаторами Adam, SGD, SignSGD и Muon. На рисунках ниже представлены результаты данного эксперимента:




(a) Loss on train dataset



(b) Accuracy on train dataset




(c) Loss on test dataset




(d) Accuracy on test dataset


Рис. 1: Сравнение сходимости и точности различных алгоритмов оптимизации на обучении классификатора MNIST. На верхнем ряду представлены результаты работы на обучающей выборке, в нижнем на тестовой.




(a) Loss on train dataset



(b) Accuracy on train dataset



(c) Loss on test dataset



(d) Accuracy on test dataset

Рис. 2: Сравнение сходимости и точности различных алгоритмов оптимизации на обучении классификатора CIFAR-10. На верхнем ряду представлены результаты работы на обучающей выборке, в нижнем на тестовой.

Затем был реализован эксперимент по федеративному обучению:




Рис. 3: Набросок ожидаемых результатов эксперимента.

6 Discussion

TODO

7 Conclusion

TODO

Список литературы

- [1] J. Bernstein et al. signSGD: Compressed Optimisation for Non-Convex Problems. 2018. URL <https://arxiv.org/abs/1802.04434>. Introduces sign-based gradient descent to reduce communication costs in distributed training.
- [2] J. Bernstein et al. signSGD with Majority Vote is Communication Efficient And Fault Tolerant. 2019. URL <https://arxiv.org/abs/1810.05291>. Prove signSGD convergence in large and mini-batch settings (establishing for a specific parameter regime ADAM convergence as a byproduct) and demonstrate that majority vote aggregation ensures robustness against up to 50% adversarial workers.
- [3] J. Bernstein and L. Newhouse. Old Optimizer, New Norm: An Anthology. 2024. URL <https://arxiv.org/abs/2409.20325>. Connects classical optimization methods with modern norm-based constraints and preconditioning.
- [4] K. Jordan et al. Muon: An Optimizer for Hidden Layers in Neural Networks. <https://kellerjordan.github.io/posts/muon/>, <https://github.com/KellerJordan/Muon>, 2024. Blog/GitHub. Proposes Muon optimizer specifically designed for hidden layers using matrix preconditioning.
- [5] I. Shah et al. Practical Efficiency of Muon for Pretraining. 2025. URL <https://arxiv.org/abs/2505.02222>. Benchmarks Muon’s practical efficiency in pretraining scenarios against standard baselines.
- [6] S. Horváth et al. Stochastic Distributed Learning with Gradient Quantization and Double-Variance Reduction. 2023. URL <https://arxiv.org/abs/1904.05115>. Provides theoretical analysis of gradient quantization and variance reduction in distributed learning for communication efficiency.
- [7] Aleksandr Beznosikov et al. On Biased Compression for Distributed Learning. 2020. URL <https://arxiv.org/abs/2002.12410>. Provides a unified theoretical framework for distributed learning with biased compression operators, such as SignSGD, and analyzes error feedback mechanisms.

- [8] Dan Alistarh et al. QSGD: Communication-Efficient SGD via Gradient Quantization and Encoding. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, 2017. URL <https://arxiv.org/abs/1610.02132>. Foundational paper on gradient quantization, introducing the trade-off between communication bandwidth and convergence guarantees.
- [9] K. Jordan. CIFAR-10 Airbench. <https://github.com/KellerJordan/cifar10-airbench>, 2023. Standardized benchmark for comparing optimizer performance on CIFAR-10 with standardized architecture.
- [10] K. Jordan et al. Modded-NanoGPT: Speedrunning the NanoGPT Baseline. <https://github.com/KellerJordan/modded-nanogpt>, 2024. Establishes a fast NanoGPT baseline for comparing optimizer performance in LLM training.
- [11] K. Gruntkowska et al. Error Feedback for Muon and Friends. 2025. URL <https://arxiv.org/abs/2510.00643>. This paper presents the EF21-Muon is the communication-efficient distributed optimizer with rigorous convergence guarantees for non-Euclidean LMO-based methods (Muon/Scion/Gluon), supporting compression and error feedback while achieving up to 7x communication savings without accuracy loss.
- [12] K. Ahn et al. Dion: Distributed Orthonormalized Updates. 2025. URL <https://arxiv.org/abs/2504.05295>. This paper presents the Dion is a scalable, distributed orthonormalization method that replaces Newton-Schulz with amortized power iteration on a momentum buffer.
- [13] T. Pethick et al. Generalized Gradient Norm Clipping & Non-Euclidean l_0, l_1 -Smoothness. 2025. URL <https://arxiv.org/abs/2506.01913>. This paper presents the Clipped Scion is a hybrid non-Euclidean optimizer combining steepest descent and conditional gradient to generalize gradient clipping, achieve descent under L_0, L_1 -smoothness, incorporate weight decay via Frank-Wolfe.
- [14] T. Pethick et al. Training Deep Learning Models with Norm-Constrained LMOs. 2025. URL <https://arxiv.org/pdf/2502.07529>. This paper presents the Scion algorithm, a memory-efficient LMO-based stochastic optimizer that adapts to geometry, integrates existing methods, accelerates nanoGPT training without using Adam.
- [15] D. Kovalev. Understanding Gradient Orthogonalization for Deep Learning via Non-Euclidean Trust-Region Optimization. 2025. URL <https://arxiv.org/abs/2503.12645>. Provides theoretical analysis of gradient orthogonalization via Non-Euclidean Trust-Region Optimization.
- [16] A. Riabinin et al. Gluon: Making Muon & Scion Great Again! (Bridging Theory and Practice of LMO-based Optimizers for LLMs). 2025. URL <https://arxiv.org/abs/2505.13416>.
- [17] N. Amsel et al. The Polar Express: Optimal Matrix Sign Methods. 2025. URL <https://arxiv.org/abs/2505.16932>. More effective replacement for Newton-Schulz iterations.
- [18] J. Li and M. Hong. A Note on the Convergence of Muon and Further. 2025. URL <https://arxiv.org/abs/2502.02900>. Provides convergence analysis for Muon, addressing theoretical gaps in LMO-based optimizers.
- [19] J. Liu et al. Muon is Scalable for LLM Training. 2025. URL <https://arxiv.org/abs/2502.16982>. Demonstrates Muon’s scalability for LLM training, validating its performance against AdamW on large-scale models.
- [20] E. Petrov et al. Leveraging Coordinate Momentum in SignSGD and Muon. 2025. URL <https://arxiv.org/abs/2506.04430>. Zeroth-order modifications for SignSGD and Muon.
- [21] A. Gupta et al. Effective Quantization of Muon Optimizer States. 2025. URL <https://arxiv.org/abs/2509.23106>. It presents 8-bit Muon with blockwise quantization, which reduces optimizer memory by up to 62% while matching full-precision Muon’s performance in LLM pre-training and fine-tuning.

A Appendix / supplemental material

A.1 Additional experiments / Proofs of Theorems

TODO