

SignMuon: fast as Muon, communication-effective as SignSGD

Смирнова Мария Александровна

Московский физико-технический институт
Физтех-школа прикладной математики и информатики
Кафедра «Интеллектуальные системы»

Апрель 2026

Задача исследования

Проблема

- В федеративном обучении передача 32-bit весов.
- Поэлементные методы (SignSGD) не учитывают 2D-структуру весов слоёв нейросети.

Решение: SignMuon

Объединить структурную LMO-ортогонализацию оптимизатора Muon с экстремальным сжатием (1-bit) от SignSGD.

Цель

Создать метод, сохраняющий матричную геометрию Muon при снижении передачи данных в 32 раза.

❶ **Bernstein et al. 2018**

SignSGD: Compressed optimisation for non-convex problems.

→ Введение знаковой компрессии для минимизации коммуникаций.

❷ **Bernstein et al. 2019**

SignSGD with Majority Vote is Communication Efficient and Fault Tolerant.

→ Метод мажоритарного голосования и робастность в распределенной среде.

❸ **Pethick et al. 2025**

Training Deep Learning Models with Norm-Constrained LMOs.

→ Теоретическое обоснование LMO-оптимизаторов (алгоритм Scion).

❹ **Takezawa et al. 2025**

FedMuon: Federated Learning with Bias-Corrected LMO-based Optimization.

→ Исследование Muon в федеративном обучении и коррекция смещения.

Постановка задачи

1. Централизованная задача:

$\mathcal{X}$ – пространство параметров, $f_{\xi}(\mathbf{X})$ – функция потерь модели с параметрами $\mathbf{X}$, вычисленную на точке обучающих данных ξ , выбранной из распределения вероятностей $\mathcal{D}$.

$$\min_{\mathbf{X} \in \mathcal{X}} \{f(\mathbf{X}) := \mathbb{E}_{\xi \sim \mathcal{D}}[f_{\xi}(\mathbf{X})]\} \quad (1)$$

2. Федеративная задача (N клиентов):

$\mathcal{X}$ – пространство параметров, $\mathbf{X} \in \mathcal{X}$ – параметры модели, $f_j(\mathbf{X})$ – функция потерь модели ($\mathbf{X}$) на данных $(\mathcal{D}_j)$, хранящихся на узле j .

$$\min_{\mathbf{X} \in \mathcal{X}} \left\{ f(\mathbf{X}) := \frac{1}{N} \sum_{j=1}^N f_j(\mathbf{X}) \right\}, \quad f_j(\mathbf{X}) = \mathbb{E}_{\xi_j \sim \mathcal{D}_j}[f(\mathbf{X}, \xi_j)] \quad (2)$$

Критерий качества

Итоговая точность (Ассигасу) на тестовой выборке и робастость метода.

Централизованный алгоритм SignMuon

Алгоритм SignMuon

- ❶ $\mathbf{M}_t = \mu \mathbf{M}_{t-1} + \mathbf{G}_t$ (momentum)
- ❷ $\mathbf{D}_t = A(\mathbf{M}_t) \approx \mathbf{U}_t \mathbf{V}_t^\top$ (LMO)
- ❸ $\mathbf{s}_t = \text{sign}(\mathbf{D}_t)$ (1-bit compression)
- ❹ $\mathbf{X}_{t+1} = \mathbf{X}_t - \eta_t \mathbf{s}_t$ (update)

Итерации Ньютона-Шульца (5-й порядок)

Аппроксимация $\mathbf{UV}^\top$ без SVD:

- $\mathbf{A} = \mathbf{Y}\mathbf{Y}^\top$
- $\mathbf{Y} = a\mathbf{Y} - b\mathbf{A}\mathbf{Y} + c\mathbf{A}^2\mathbf{Y}$

* Были приняты следующие константы:

$a \approx 3.44$, $b \approx 4.77$, $c \approx 2.03$

* Векторные параметры ($n_{\text{dim}} = 1$) оптимизируются AdamW.

Определение LMO-оракула:

$$A(\mathbf{X}) = \arg \min_{\|\mathbf{Y}\| \leq 1} \langle \mathbf{X}, \mathbf{Y} \rangle$$

Выбирает направление наискорейшего спуска в спектральной норме.

Ключевые особенности:

- Ортогонализация
- **SignA Family:** SignMuon берет знак *после* LMO-шага, сохраняя матричную структуру.

Федеративный алгоритм SignMuon

Локально на клиенте m

1 Accumulation:

$$\mathbf{G}_t^{(j)} = \frac{1}{n_{\text{steps}}} \sum_{i=1}^{n_{\text{steps}}} \nabla f(\mathbf{X}_t; \xi_{t,i}^{(j)})$$

2 Client Momentum:

$$\mathbf{M}_t^{(j)} = \mu \mathbf{M}_{t-1}^{(j)} + \mathbf{G}_t^{(j)}$$

3 LMO + Compression:

$$\mathbf{s}_t^{(j)} = \text{sign}(A(\mathbf{M}_t^{(j)}))$$

4 Upload: Отправка знаков $\mathbf{s}_t^{(j)} \in \{\pm 1\}^{m \times n}$ на сервер.

Агрегация на сервере

1 Majority Vote:

$$\mathbf{s}_t^{\text{agg}} = \text{sign} \left(\sum_{j=1}^N \mathbf{s}_t^{(j)} \right)$$

2 Global Update:

$$\mathbf{X}_{t+1} = \mathbf{X}_t - \eta_t \mathbf{s}_t^{\text{agg}}$$

3 Classifier Update: Последний слой обновляется AdamW по $\mathbf{s}_t^{\text{agg}}$.

Ключевое преимущество

Client Momentum + LMO сохраняют геометрию ортонормированных обновлений, а **Majority Vote** обеспечивает робастность при передаче всего **1 бита** на параметр.

Стандартные предположения

- **Спектральная норма:** $\|\mathbf{X}\|_2 = \sigma_{\max}(\mathbf{X})$
- **Дуальная норма:** $\|\mathbf{X}\|_* = \sum_i \sigma_i(\mathbf{X})$

Предположения

- **Lower Boundedness:** Целевая функция $f(\mathbf{X})$ ограничена снизу некоторым значением f^* , то есть $f(\mathbf{X}) \geq f^*$ для всех $\mathbf{X} \in \mathcal{X}$.
- **L-Smoothness** Функция $f(\mathbf{X})$ является L -гладкой относительно спектральной нормы $\|\cdot\|_2$: $\forall \mathbf{X}, \mathbf{Y} \in \mathcal{X}$, $\|\cdot\|_*$ – дуальная норма

$$\|\nabla f(\mathbf{X}) - \nabla f(\mathbf{Y})\|_* \leq L \|\mathbf{X} - \mathbf{Y}\|_2. \quad (3)$$

- **Stochastic Gradient:**
- Unbiased:

$$\mathbb{E}_{\xi \sim \mathcal{D}_j} [\nabla f_j(\mathbf{X}; \xi)] = \nabla f_j(\mathbf{X}), \quad (4)$$

- Bounded variance:

$$\mathbb{E}_{\xi \sim \mathcal{D}_j} [\|\nabla f_j(\mathbf{X}; \xi) - \nabla f_j(\mathbf{X})\|_*^2] \leq \sigma^2, \quad \sigma > 0. \quad (5)$$

Стандартные предположения

Гипотеза 1: Сходимость

При выполнении условий **Assumption** алгоритм сходится в гладком невыпуклом режиме со скоростью:

$$\min_{0 \leq t \leq T} \mathbb{E}[\|\nabla f(\mathbf{X}_t)\|_*^2] = \mathcal{O}(T^{-1/2}).$$

Гипотеза 2: Сохранение геометрии и робастность

Знаковая компрессия LMO-направления $\text{sign}(\mathbf{UV}^\top)$ сохраняет геометрию ортогональных обновлений. Это обеспечивает у SignMuon:

- **Качество:** Точность, сопоставимую с Muon.
- **Робастность:** Устойчивость к высокому темпу обучения, при котором Adam и SignSGD расходятся.

Вычислительные эксперименты: Синтетический тест

Гладкая выпуклая задача

Задача минимизации сильно коррелированной квадратичной формы:

$$F(\mathbf{X}) = \frac{1}{2} \|\mathbf{M}^{1/2} \mathbf{X} \mathbf{N}^{1/2}\|_F^2 = \frac{1}{2} \langle \mathbf{X}, \mathbf{M} \mathbf{X} \mathbf{N} \rangle \rightarrow \min_{\mathbf{X} \in \mathbb{R}^{m \times n}}, \quad (6)$$


где матрица параметров $\mathbf{X} \in \mathbb{R}^{m \times n}$ имеет размерность $m = 500$ и $n = 500$. Для генерации данных случайным образом задаем спектры матриц $\mathbf{M}$ и $\mathbf{N}$, равномерно распределяя их собственные значения на интервале $(0, 1)$.

Подбор параметров


- моментум $\mu \in \{0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9, 0.95\}$ для всех алгоритмов, кроме Adam;
- темп $\eta \in [0.005, 0.020]$ с шагом 0.001 для Muon;
- темп $\eta \in [1 \cdot 10^{-4}, 0.001]$ с шагом 10^{-4} для SignMuon;
- темп $\eta \in [5 \cdot 10^{-5}, 2 \cdot 10^{-4}]$ с шагом 10^{-5} для SignSGD;
- темп $\eta \in [0.01, 0.10]$ с шагом 0.01 для SGD и Adam.

Вычислительные эксперименты: Синтетический тест

Результаты с оптимальными гиперпараметрами, обеспечивающие достижение $F(\mathbf{X}) \leq 0.001$ за наименьшее число итераций.



(a) The Loss



(b) The Gradient Norm

Algorithm	learning rate (η)	momentum (μ)	Iterations to 0.001
SignMuon	0.0002	0.2	2104
Muon	0.0065	0.1	1122
SignSGD	0.00015	0.8	3120
SGD	0.1	0.95	972
Adam	0.007	-	202

Вычислительные эксперименты: Setup

Наборы данных

CIFAR-10: 60k цветных изображений, $3 \times 32 \times 32$ (RGB), 10 классов.

Augmentation:

- Random Horizontal Flip
- Random Crop (32x32, pad 4)

Метрики качества

Accuracy:

$$\frac{1}{N} \sum_{i=1}^N \mathbb{I}(\hat{y}_i = y_i) \times 100\%$$

Loss:

$$\mathcal{L} = -\frac{1}{N} \sum y_{i,c} \log(\hat{p}_{i,c})$$

Конфигурация обучения

Architecture: 4-слойная CNN.

LMO: Newton-Schulz 5-го порядка

Momentum: Nesterov (0.9).


Scheduler: Cosine Annealing:

$$\eta_t = \eta_{min} + \frac{\eta_{max} - \eta_{min}}{2} \left(1 + \cos \frac{t\pi}{T_{max}} \right)$$


Оптимизаторы

- 1 **SignMuon (Proposed)**
- 2 Muon
- 3 SignSGD
- 4 SGD
- 5 Adam


Централизованное обучение




(a) Loss on train dataset



(b) Accuracy on train dataset




(c) Loss on test dataset




(d) Accuracy on test dataset

Федеративное обучение: Масштабирование SignMuon



(a) Loss on test dataset



(b) Accuracy on test dataset


Итоговая точность (Test Accuracy) после 2000 раундов:

Число клиентов	1	3	5	7	9
Точность (Accuracy)	76.13%	81.24%	82.87%	83.54%	82.88%


Вывод: Увеличение числа участников повышает стабильность и итоговое качество SignMuon.

Федеративное обучение: Сравнение алгоритмов

($n_{\text{lients}} = 3, n_{\text{step}} = 1$)



(a) Loss on test dataset




(b) Accuracy on test dataset

Алгоритм	Трафик	Точность
SignMuon	1-bit	81.24%
Muon	32-bit	81.27%
SignSGD	1-bit	65.96%
SGD	32-bit	76.77%
Adam	32-bit	70.83%


По качеству SignMuon незначительно отстает относительно Muon и опережает SignSGD.

Федеративное обучение: Сравнение алгоритмов

($n_{\text{lients}} = 10$, $n_{\text{step}} = 3$)



(a) Loss on test dataset



(b) Accuracy on test dataset

Алгоритм	Трафик	Точность
SignMuon	1-bit	84.57%
Muon	32-bit	85.22%
SignSGD	1-bit	78.98%
SGD	32-bit	81.38%
Adam	32-bit	78.36%

По качеству SignMuon незначительно отстает относительно Muon и опережает SignSGD.

Выводы:

- 1 Разработан алгоритм **SignMuon**, объединяющий LMO и 1-битную компрессию.
- 2 Эмперически доказана высокая робастность метода к гиперпараметрам.
- 3 Метод превосходит SignSGD по точности при идентичной нагрузке на сеть.
- 4 Решена проблема коммуникационного узкого места для матричных оптимизаторов в федеративном обучении.