SignMuon: fast as Muon, communication-efficient as SignSGD

The poster will be updated and translated into English once we receive the decision at ICOMP

Смирнова Мария[1] Кравацкий Алексей [1]

[1]Московский физико-технический институт

Введение

Современные методы обучения глубоких нейронных сетей требуют использования оптимизаторов, которые не только обеспечивают высокую скорость сходимости, но и минимизируют коммуникационные издержки в распределенных системах. В условиях федеративного обучения данные распределены между узлами, которые обмениваются информацией с сервером для обучения общей модели. Каждый узел имеет локальный набор данных, а целью федеративного обучения является минимизация усредненной функции потерь по всем узлам. В условиях низкой пропускной способности сети передача полных матриц обновлений модели может замедлять её скорость обучения. Для решения этой проблемы обычно используются методы компрессии градиентов (1; 2; 3).

В данной работе мы предлагаем алгоритм SignMuon, который применяет знаковую компрессию к LMO-обновлению оптимизатора Muon. В отличие от SignSGD, который передаёт знак координат направления стохастического градиента, наш метод сначала вычисляет направление обновления с помощью LMO (Linear Minimization Oracle), как Muon, а затем передаёт только знак этого направления. Такая схема позволяет учитывать матричную структуру параметров и сохранять преимущества Muon, одновременно сокращая объём передаваемой информации до одного бита на координату. Тем самым SignMuon стремится объединить быструю сходимость структурированных оптимизаторов с коммуникационной эффективностью знаковых методов.

Постановка задачи

Централизованное обучение Рассмотрим стохастическую задачу оптимизации:

$$\min_{\mathbf{X}\in\mathcal{X}}\{f(\mathbf{X}) := \mathbb{E}_{\xi\sim\mathcal{D}}[f_\xi(\mathbf{X})]\}, \tag{1}$$

где $\mathcal{X}$ – пространство параметров (например, $\mathbb{R}^d$ или $\mathbb{R}^{m\times n}$), функции $f_\xi : \mathcal{X} \to \mathbb{R}$ могут быть невыпуклыми и негладкими, но являются непрерывно дифференцируемыми. Здесь $f_\xi(\mathbf{X})$ представляет собой функцию потерь модели с параметрами $\mathbf{X} \in \mathcal{X}$, вычисленной по обучающим данным, выбранным из распределения вероятностей $\mathcal{D}$.

В данном сценарии SignMuon инициализирует буфер моментума $\mathbf{M}_0 = \mathbf{0}$, а затем на каждой итерации $t \geq 1$ выполняет следующую последовательность обновлений:

$$\begin{aligned}
\mathbf{M}_t &= \mu\mathbf{M}_{t-1} + \mathbf{G}_t && \text{(Momentum accumulation)}\\
\tilde{\mathbf{M}}_t &= \begin{cases} \mathbf{G}_t + \mu\mathbf{M}_t & \text{(Nesterov momentum),}\\ \mathbf{M}_t & \text{(otherwise)}\end{cases} && \text{(Effective direction),}\\
\mathbf{D}_t &= \mathrm{LMO}(\tilde{\mathbf{M}}_t) = \mathrm{LMO}(\mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top) = \mathbf{U}\mathbf{V}^\top \in \mathbb{R}^{m\times n},\\
\mathbf{s}_t &= \mathrm{sign}(\mathbf{D}_t) \in \{\pm 1\}^{m\times n}, && \text{(Sign compression)}\\
\mathbf{X}_{t+1} &= \mathbf{X}_t - \eta_t\mathbf{s}_t && \text{(Parameter update),}
\end{aligned} \tag{2}$$

где $\mathbf{X}_t \in \mathbb{R}^{m\times n}$ — текущая матрица параметров модели, $\mathbf{G}_t$ — её стохастический градиент, $\mathbf{U} \in \mathbb{R}^{m\times r}$, $\mathbf{V} \in \mathbb{R}^{n\times r}$ – ортонормированные матрицы сингулярных векторов, $\mathbf{\Sigma} \in \mathbb{R}^{r\times r}$ – диагональная матрица сингулярных значений, $\mu \in [0, 1)$ – коэффициент моментума, η_t – темп обучения, а функция $\mathrm{sign}(\cdot)$ применяется поэлементно к полученному направлению $\mathbf{D}_t$.

Федеративное обучение Решается задача:

$$\min_{\mathbf{X}\in\mathcal{X}}\left\{f(\mathbf{X}) := \frac{1}{N}\sum_{j=1}^{N} f_j(\mathbf{X})\right\}, \quad f_j(\mathbf{X}) = \mathbb{E}_{\xi_j\sim\mathcal{D}_j}[f(\mathbf{X}, \xi_j)] \tag{3}$$

где $\mathcal{X}$ – пространство параметров (например, $\mathbb{R}^d$ или $\mathbb{R}^{m\times n}$), $\mathbf{X} \in \mathcal{X}$ – параметры модели, $N \geq 1$ – количество узлов, а $f_j(\mathbf{X})$ – функция потерь модели $\mathbf{X}$ на данных $\mathcal{D}_j$, хранящихся на узле $j \in [N] := \{1, \ldots, N\}$.

В федеративном сценарии использования алгоритма SignMuon сервер выполняет роль агрегатора, а основная структурная оптимизация происходит на узлах. В начале раунда t каждый узел j копирует глобальную модель. Вместо выполнения локальных шагов изменения параметров, узел вычисляет усреднённый стохастический градиент, накапливая его по n_steps мини-батчам локальных данных.

Algorithm 1 Federated SignMuon

Input: Начальная модель $\mathbf{X}_0$, число узлов N, число раундов rounds, число локальных шагов n_steps, шаг обучения η_t (для основных слоёв), шаг обучения η_t^{aux} (для последнего слоя), коэффициент моментума μ

Output: Обновлённая глобальная модель $\mathbf{X}$

for $j = 1$ to N **do**
  $\mathbf{M}_0^{(j)} \quad 0$ ▷ Инициализация локальных буферов на узлах
end for
Инициализация AdamW для last_layer с lr = η_{aux}
for $t = 1$ to rounds **do**
  for $j = 1$ to N **in parallel do**
    $\mathbf{X}_t^{(j)} \leftarrow \mathbf{X}_t$ ▷ Получение глобальной модели
    for $k = 1$ to n_steps **do**
      Сэмплировать батч $\xi_{t,k}^{(j)}$
      $\nabla f_k \quad \nabla f(\mathbf{X}_t^{(j)}; \xi_{t,k}^{(j)})$
      $\mathbf{G}_t^{(j)} \quad \mathbf{G}_t^{(j)} + \nabla f_k$
    end for

    $\mathbf{G}_t^{(j)} \quad \mathbf{G}_t^{(j)}/\text{n_steps}$ ▷ Усреднение градиентов
    $\mathbf{M}_t^{(j)} \quad \mu\mathbf{M}_{t-1}^{(j)} + \mathbf{G}_t^{(j)}$ ▷ Обновление локального моментума
    $\mathbf{Y}_t^{(j)} \quad \text{ReshapeTo2D}(\mathbf{M}_t^{(j)})$ ▷ Приведение моментума к матрице $m \times n$
    for $k = 1$ to ns_steps **do** ▷ Ортогонализация (Muon LMO)
      $\mathbf{A}_t^{(j)} \quad \mathbf{Y}_t^{(j)}(\mathbf{Y}_t^{(j)})^\top$
      $\mathbf{Y}_t^{(j)} \quad a\,\mathbf{Y}_t^{(j)} - b\,\mathbf{A}_t^{(j)}\mathbf{Y}_t^{(j)} + c\,(\mathbf{A}_t^{(j)})^2\mathbf{Y}_t^{(j)}$
    end for
    $\mathbf{D}_t^{(j)} \quad \text{ReshapeToOriginal}(\mathbf{Y}_t^{(j)})$
    $\mathbf{s}_t^{(j)} \quad \mathrm{sign}(\mathbf{D}_t^{(j)})$ ▷ Знаковая компрессия
    Отправить $\mathbf{s}_t^{(j)}$ на сервер
  end for
  $\mathbf{s}_t^{\text{agg}} \quad \mathrm{sign}\left(\sum_{j=1}^{N}\mathbf{s}_t^{(j)}\right)$ ▷ Majority-vote агрегация на сервере

  $\mathbf{X}_{t+1} \leftarrow \mathbf{X}_t - \eta_t\mathbf{s}_t^{\text{agg}}$ ▷ Обновление матричных параметров

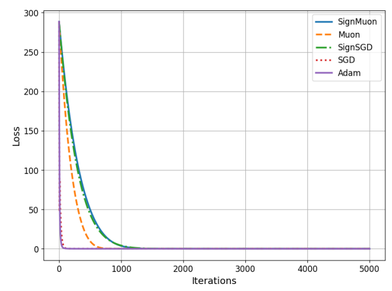
  $\mathbf{X}_{t+1}^{\text{last}} \leftarrow \text{AdamW}(\mathbf{X}_t^{\text{last}}, \mathbf{s}_t^{\text{agg}}, \eta_t^{\text{aux}})$ ▷ Обновление последнего слоя
end for
return $\mathbf{X}_{\text{rounds}}$

Эксперименты и Результаты

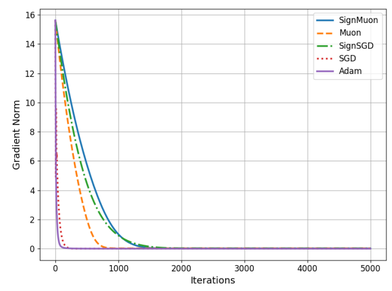
Минимизация гладкой выпуклой функции:

$$F(\mathbf{X}) = \frac{1}{2}\|\mathbf{M}^{1/2}\mathbf{X}\mathbf{N}^{1/2}\|_F^2 = \frac{1}{2}\langle\mathbf{X}, \mathbf{M}\mathbf{X}\mathbf{N}\rangle \to \min_{\mathbf{X}\in\mathbb{R}^{m\times n}}, \tag{4}$$

где $\mathbf{X} \in \mathbb{R}^{m\times n}$ $(m = n = 500)$, $\mathbf{M} \in \mathbb{S}_+^m$ и $\mathbf{N} \in \mathbb{S}_+^n$.



(a) Loss



(b) Frobenius gradient norm

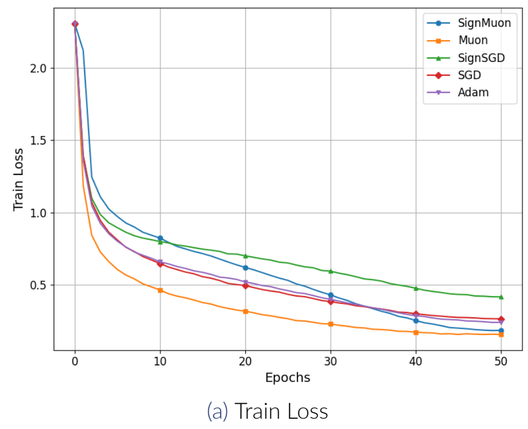
Algorithm	Iterations to 0.001
SignMuon	2104
Muon	1122
SignSGD	3120
SGD	972
Adam	202

(c) Iterations

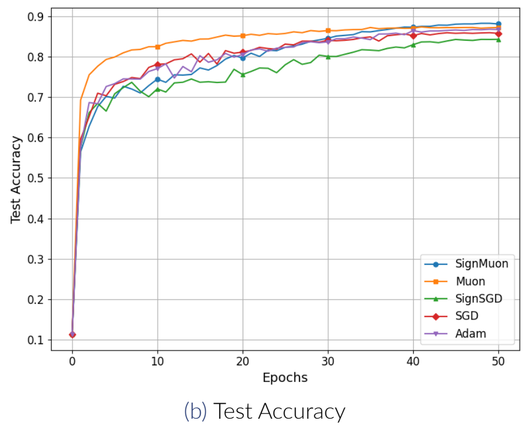
Figure 1. Сравнение оптимизаторов на гладкой выпуклой задаче (уравнение 4). Показано наименьшее число итераций, обеспечивающее достижение $F(\mathbf{X}) \leq 0.001$.

Централизованное обучение:

Dataset	Optimizer	Epoch	Batch	LR	LR Aux	Mom	Train Acc	Test Acc
CIFAR-10	SignMuon	50	128	0.015	0.001	0.9	93.81%	88.05%
	Muon			0.015			94.56%	87.16%
	Adam			0.001			92.08%	86.67%
	SGD			0.015			91.07%	85.72%
	SignSGD			0.001			85.57%	84.24%



(a) Train Loss



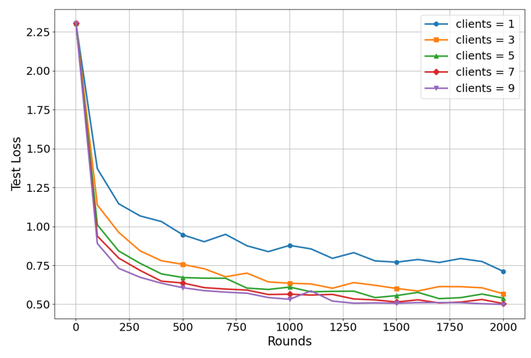
(b) Test Accuracy

Figure 2. Централизованный сценарий. Сравнение сходимости и точности классификации на CIFAR-10 для двухслойной сверточной нейронной сети при использовании различных оптимизаторов.

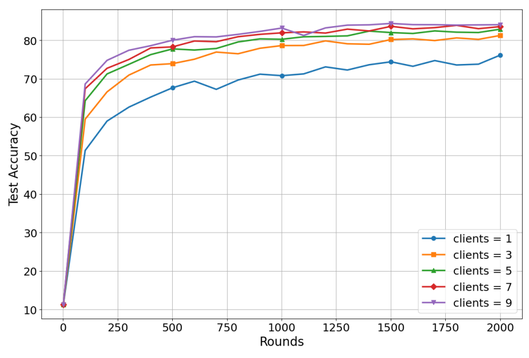
Федеративное обучение: Зависимость от числа узлов

Table 1. Итоговая точность SignMuon после 2000 раундов

Число узлов	1	3	5	7	9
Точность (Accuracy)	76.13%	81.24%	82.87%	83.54%	84.03%

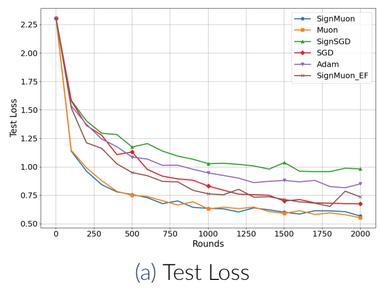


(a) Test Loss

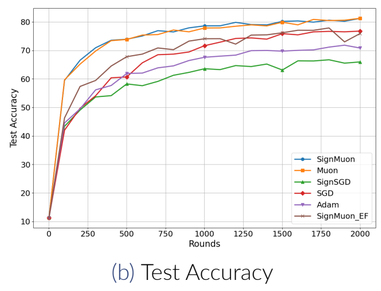


(b) Test Accuracy

Федеративное обучение: Сравнение алгоритмов ($N = 3, n_{steps} = 1$) и ($N = 10, n_{steps} = 3$)



(a) Test Loss

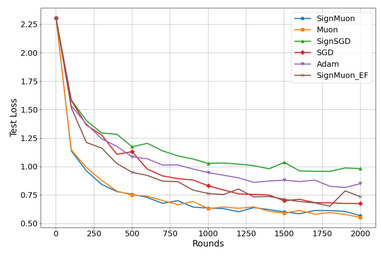


(b) Test Accuracy

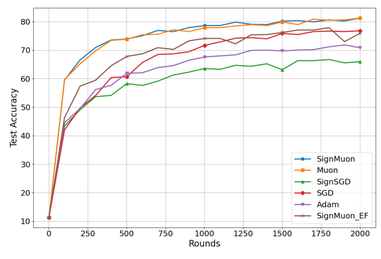
Алгоритм	Трафик	Точность
SignMuon	1-bit	81.24%
Muon	32-bit	81.27%
SignSGD	1-bit	65.96%
SGD	32-bit	76.77%
Adam	32-bit	70.83%

(c) Results

Figure 4. Федеративное обучение. Сравнение разных алгоритмов при $N = 3, n_{steps} = 1$.



(a) Test Loss



(b) Test Accuracy

Алгоритм	Трафик	Точность
SignMuon	1-bit	84.57%
Muon	32-bit	85.22%
SignSGD	1-bit	78.98%
SGD	32-bit	81.38%
Adam	32-bit	78.36%

(c) Results

Figure 5. Федеративное обучение. Сравнение разных алгоритмов при $N = 10, n_{steps} = 3$.

Основные источники

[1] J. Bernstein et al. *signSGD: Compressed Optimisation for Non-Convex Problems*. International Conference on Machine Learning, 2018.

[2] J. Bernstein et al. *signSGD with Majority Vote is Communication Efficient And Fault Tolerant*. International Conference on Learning Representations, 2019.

[3] A. Beznosikov et al. *On Biased Compression for Distributed Learning*. Journal of Machine Learning Research, 2023.

[4] T. Pethick et al. *Training Deep Learning Models with Norm-Constrained LMOs*. International Conference on Machine Learning, 2025.