

SignMuon: fast as Muon, communication-effective as SignSGD

Смирнова Мария Александровна

Московский физико-технический институт
Физтех-школа прикладной математики и информатики
Кафедра «Интеллектуальные системы»

Апрель 2026

Цель исследования

Проблема

- В распределенном обучении передачу 32 bit весов — узкое место.
- Поэлементные методы (SignSGD) игнорируют 2D-структуру весов слоёв нейросети.

Предложение: SignMuon

Объединить структурную ортогонализацию (LMO) оптимизатора Muon с экстремальным сжатием (1-bit) от SignSGD.

Цель

Создать метод, сохраняющий матричную геометрию Muon при снижении трафика в 32 раза.

❶ **Jeremy Bernstein et al. (2018)**

SignSGD: Compressed optimisation for non-convex problems.

→ Введение знаковой компрессии для минимизации коммуникаций.

❷ **Jeremy Bernstein et al. (2019)**

SignSGD with Majority Vote is Communication Efficient and Fault Tolerant.

→ Метод мажоритарного голосования и робастность в распределенной среде.

❸ **Thomas Pethick et al. (2025)**

Training Deep Learning Models with Norm-Constrained LMOs.

→ Теоретическое обоснование LMO-оптимизаторов (алгоритм Scion).

❹ **Yuki Takezawa et al. (2025)**

FedMuon: Federated Learning with Bias-Corrected LMO-based Optimization.

→ Исследование Muon в федеративном обучении и коррекция смещения.

Постановка задачи

1. Централизованная задача:

ξ – случайный вектор неизвестного распределения $\mathcal{J}$,
 $f(\mathbf{x}, \xi)$ – функция потерь модели (loss function)
 $\mathbf{x} \in \mathbb{R}^d$ – вектор всех параметров

$$\min_{\mathbf{x} \in \mathbb{R}^d} f(\mathbf{x}) = \mathbb{E}_{\xi \sim \mathcal{J}}[f(\mathbf{x}, \xi)]$$

2. Федеративная задача (M клиентов):

Данные распределены по M узлам, $\forall m \in [0, M - 1]$: D_m – локальная выборка размера $|D_m|$, локальная функция потерь $f_m(\mathbf{x}) = \mathbb{E}_{\xi \sim D_m}[f(\mathbf{x}, \xi)]$

$$F(\mathbf{x}) = \frac{1}{M} \sum_{m=1}^M \underbrace{f_m(\mathbf{x})}_{\text{local loss}} \rightarrow \min_{\mathbf{x}}$$

Критерий качества

- Итоговая точность (Accuracy) на тестовой выборке.

Централизованный алгоритм SignMuon

Алгоритм SignMuon (для матриц)

- ❶ $\mathbf{M}_t = \mu \mathbf{M}_{t-1} + \mathbf{G}_t$ (momentum)
- ❷ $\mathbf{D}_t = A(\mathbf{M}_t) \approx \mathbf{U}_t \mathbf{V}_t^\top$ (LMO)
- ❸ $\mathbf{s}_t = \text{sign}(\mathbf{D}_t)$ (1-bit compression)
- ❹ $\mathbf{X}_{t+1} = \mathbf{X}_t - \eta_t \mathbf{s}_t$ (update)

Итерации Ньютона-Шульца (5-й порядок)

Аппроксимация $\mathbf{UV}^\top$ без SVD:

- $\mathbf{A} = \mathbf{Y}\mathbf{Y}^\top$
- $\mathbf{Y} = a\mathbf{Y} - b\mathbf{A}\mathbf{Y} + c\mathbf{A}^2\mathbf{Y}$

* Были приняты следующие константы:

$a \approx 3.44$, $b \approx 4.77$, $c \approx 2.03$

* Векторные параметры ($n_{\text{dim}} = 1$) оптимизируются AdamW.

Определение LMO-оракула:

$$A(\mathbf{G}) = \arg \min_{\|\mathbf{D}\|_2 \leq 1} \langle \mathbf{G}, \mathbf{D} \rangle$$

Выбирает направление наискорейшего спуска в спектральной норме.

Ключевые особенности:

- Ортогонализация
- **SignA Family:** SignMuon берет знак *после* LMO-шага, сохраняя матричную структуру.

Федеративный алгоритм SignMuon

Локально на клиенте m

1 Accumulation:

$$\mathbf{G}_t^{(m)} = \frac{1}{n_{\text{steps}}} \sum_{i=1}^{n_{\text{steps}}} \nabla f(\mathbf{X}_t; \xi_{t,i}^{(m)})$$

2 Client Momentum:

$$\mathbf{M}_t^{(m)} = \mu \mathbf{M}_{t-1}^{(m)} + \mathbf{G}_t^{(m)}$$

3 LMO + Compression:

$$\mathbf{s}_t^{(m)} = \text{sign}(A(\mathbf{M}_t^{(m)}))$$

4 Upload: Отправка знаков $\mathbf{s}_t^{(m)} \in \{\pm 1\}^{m \times n}$ на сервер.

Агрегация на сервере

1 Majority Vote:

$$\mathbf{s}_t^{\text{agg}} = \text{sign} \left(\sum_{m=1}^M \mathbf{s}_t^{(m)} \right)$$

2 Global Update:

$$\mathbf{X}_{t+1} = \mathbf{X}_t - \eta_t \mathbf{s}_t^{\text{agg}}$$

3 Classifier Update: Последний слой обновляется AdamW по $\mathbf{s}_t^{\text{agg}}$.

Ключевое преимущество

Локальный моментум и LMO сохраняют структуру весов, а **Majority Vote** обеспечивает робастность при передаче всего **1 бита** на параметр.

Стандартные предположения

- **Спектральная норма:** $\|\mathbf{X}\|_2 = \sigma_{\max}(\mathbf{X})$
- **Дуальная норма:** $\|\mathbf{X}\|_* = \sum_i \sigma_i(\mathbf{X})$

Assumptions

- **Lower Boundedness:** Целевая функция $F(\mathbf{x})$ ограничена снизу некоторым значением F^* , то есть $F(\mathbf{x}) \geq F^*$ для всех $\mathbf{x} \in \mathbb{R}^d$.
- **L-Smoothness** Функция $F(\mathbf{x})$ является L -гладкой относительно нормы $\|\cdot\|$, т.е. для любых $\mathbf{x}, \mathbf{y} \in \mathbb{R}^d$ выполняется:

$$\|\nabla F(\mathbf{x}) - \nabla F(\mathbf{y})\|_* \leq L\|\mathbf{x} - \mathbf{y}\| \quad (1)$$

- **Stochastic Gradient:**
- Unbiased:

$$\mathbb{E}_{\xi} [\nabla f(\mathbf{x}; \xi)] = \nabla f(\mathbf{x}), \quad (2)$$

- Bounded variance:

$$\mathbb{E}_{\xi} [\|\nabla f(\mathbf{x}; \xi) - \nabla f(\mathbf{x})\|_*^2] \leq \sigma^2, \quad \sigma > 0 \quad (3)$$

Стандартные предположения

Гипотеза 1: Сходимость

При выполнении условий **Assumption** алгоритм сходится в гладком невыпуклом режиме со скоростью:

$$\min_{0 \leq t \leq T} \mathbb{E}[\|\nabla F(\mathbf{x}_t)\|_*^2] = \mathcal{O}(T^{-1/2}).$$

Гипотеза 2: Сохранение геометрии и робастность

Знаковая компрессия LMO-направления $\text{sign}(\mathbf{UV}^\top)$ сохраняет геометрию ортогональных обновлений. Это обеспечивает у SignMuon:

- **Качество:** Точность, сопоставимую с Muon.
- **Робастность:** Устойчивость к высокому темпу обучения, при котором Adam и SignSGD расходятся.

Вычислительные эксперименты: Setup

Наборы данных

- **CIFAR-10:** 60к цветных изображений, $3 \times 32 \times 32$ (RGB).
- **Augmentation:**
 - ▶ Random Horizontal Flip
 - ▶ Random Crop (32x32, pad 4)

Метрики качества

- **Accuracy:**

$$\frac{1}{N} \sum_{i=1}^N \mathbb{I}(\hat{y}_i = y_i) \times 100\%$$

- **Loss:**

$$\mathcal{L} = -\frac{1}{N} \sum y_{i,c} \log(\hat{p}_{i,c})$$

Конфигурация обучения


- **Architecture:** 4-слойная CNN.
- **LMO:** Newton-Schulz 5-го порядка
- **Momentum:** Nesterov (0.9).
- **Scheduler:** Cosine Annealing:

$$\eta_t = \eta_{min} + \frac{\eta_{max} - \eta_{min}}{2} \left(1 + \cos \frac{t\pi}{T_{max}} \right)$$


Оптимизаторы

- **SignMuon (Proposed)**
- Muon
- SignSGD
- SGD
- Adam


Централизованное обучение




(a) Loss on train dataset



(b) Accuracy on train dataset




(c) Loss on test dataset




(d) Accuracy on test dataset

Федеративное обучение: Масштабирование SignMuon



(a) Loss on test dataset



(b) Accuracy on test dataset


Итоговая точность (Test Accuracy) после 2000 раундов:

Число клиентов	1	3	5	7	9
Точность (Accuracy)	73.28%	79.27%	81.01%	82.85%	82.88%


Вывод: Увеличение числа участников повышает стабильность и итоговое качество SignMuon.

Федеративное обучение: Сравнение алгоритмов

($n_{\text{lients}} = 3, n_{\text{step}} = 1$)



(a) Loss on test dataset




(b) Accuracy on test dataset

Алгоритм	Режим	Точность (Асс)	Трафик
Muon	32-bit	80.12%	$32 \times d$
SignMuon	1-bit	79.27%	$1 \times d$
Adam	32-bit	70.83%	$32 \times d$
SignSGD	1-bit	65.96%	$1 \times d$


SignMuon практически не теряет в качестве относительно Muon, значительно превосходя SignSGD.

Федеративное обучение: Сравнение алгоритмов

($n_{\text{lients}} = 10$, $n_{\text{step}} = 3$)



(a) Loss on test dataset



(b) Accuracy on test dataset

Алгоритм	Режим	Точность (Асс)	Трафик
SignMuon	1-bit	84.93%	$1 \times d$
Muon	32-bit	84.63%	$32 \times d$
SignSGD	1-bit	78.98%	$1 \times d$
Adam	32-bit	78.36%	$32 \times d$

В режиме с накоплением градиента SignMuon показывает лучший результат среди методов.

Основные результаты

- 1 Разработан алгоритм **SignMuon**, объединяющий LMO и 1-битную компрессию.
- 2 Доказана (эмпирически) высокая робастность метода к гиперпараметрам.
- 3 Метод превосходит SignSGD по точности при идентичной нагрузке на сеть.
- 4 Решена проблема коммуникационного узкого места для матричных оптимизаторов в федеративном обучении.