

SignMuon: fast as Muon, communication-efficient as SignSGD

Смирнова Мария¹ Кравацкий Алексей¹

¹Московский физико-технический институт

Введение

Современные методы обучения глубоких нейронных сетей требуют использования оптимизаторов, которые не только обеспечивают высокую скорость сходимости, но и минимизируют коммуникационные издержки в распределенных системах. В условиях федеративного обучения данные распределены между узлами, которые обмениваются информацией с сервером для обучения общей модели. Каждый узел имеет локальный набор данных, а целью федеративного обучения является минимизация усредненной функции потерь по всем узлам. В условиях низкой пропускной способности сети передача полных матриц обновлений модели может замедлять её скорость обучения. Для решения этой проблемы обычно используются методы компрессии градиентов (1; 2; 3).

В данной работе мы предлагаем алгоритм SignMuon, который применяет знаковую компрессию к LMO-обновлению оптимизатора Muon. В отличие от SignSGD, который передаёт знак координат направления стохастического градиента, наш метод сначала вычисляет направление обновления с помощью LMO (Linear Minimization Oracle), как Muon, а затем передаёт только знак этого направления. Такая схема позволяет учитывать матричную структуру параметров и сохранять преимущества Muon, одновременно сокращая объём передаваемой информации до одного бита на координату. Тем самым SignMuon стремится объединить быструю сходимость структурированных оптимизаторов с коммуникационной эффективностью знаковых методов.

Постановка задачи

Централизованное обучение Рассмотрим стохастическую задачу оптимизации:

$$\min_{\mathbf{X} \in \mathcal{X}} \{f(\mathbf{X}) := \mathbb{E}_{\xi \sim \mathcal{D}}[f_{\xi}(\mathbf{X})]\}, \quad (1)$$

где $\mathcal{X}$ – пространство параметров (например, $\mathbb{R}^d$ или $\mathbb{R}^{m \times n}$), функции $f_{\xi} : \mathcal{X} \rightarrow \mathbb{R}$ могут быть невыпуклыми и негладкими, но являются непрерывно дифференцируемыми. Здесь $f_{\xi}(\mathbf{X})$ представляет собой функцию потерь модели с параметрами $\mathbf{X} \in \mathcal{X}$, вычисленной по обучающим данным, выбранным из распределения вероятностей $\mathcal{D}$.

В данном сценарии SignMuon инициализирует буфер момента $\mathbf{M}_0 = \mathbf{0}$, а затем на каждой итерации $t \geq 1$ выполняет следующую последовательность обновлений:

$$\begin{aligned} \mathbf{M}_t &= \mu \mathbf{M}_{t-1} + \mathbf{G}_t && \text{(Momentum accumulation)} \\ \tilde{\mathbf{M}}_t &= \begin{cases} \mathbf{G}_t + \mu \mathbf{M}_t & \text{(Nesterov momentum),} \\ \mathbf{M}_t & \text{(otherwise)} \end{cases} && \text{(Effective direction),} \\ \mathbf{D}_t &= \text{LMO}(\tilde{\mathbf{M}}_t) = \text{LMO}(\mathbf{U}\Sigma\mathbf{V}^T) = \mathbf{U}\mathbf{V}^T \in \mathbb{R}^{m \times n}, \\ \mathbf{s}_t &= \text{sign}(\mathbf{D}_t) \in \{\pm 1\}^{m \times n}, && \text{(Sign compression)} \\ \mathbf{X}_{t+1} &= \mathbf{X}_t - \eta_t \mathbf{s}_t && \text{(Parameter update),} \end{aligned} \quad (2)$$

где $\mathbf{X}_t \in \mathbb{R}^{m \times n}$ – текущая матрица параметров модели, $\mathbf{G}_t$ – её стохастический градиент, $\mathbf{U} \in \mathbb{R}^{m \times r}$, $\mathbf{V} \in \mathbb{R}^{n \times r}$ – ортонормированные матрицы сингулярных векторов, $\Sigma \in \mathbb{R}^{r \times r}$ – диагональная матрица сингулярных значений, $\mu \in [0, 1]$ – коэффициент момента, η_t – темп обучения, а функция $\text{sign}(\cdot)$ применяется поэлементно к полученному направлению $\mathbf{D}_t$.

Федеративное обучение Решается задача:

$$\min_{\mathbf{X} \in \mathcal{X}} \left\{ f(\mathbf{X}) := \frac{1}{N} \sum_{j=1}^N f_j(\mathbf{X}) \right\}, \quad f_j(\mathbf{X}) = \mathbb{E}_{\xi_j \sim \mathcal{D}_j}[f(\mathbf{X}, \xi_j)] \quad (3)$$

где $\mathcal{X}$ – пространство параметров (например, $\mathbb{R}^d$ или $\mathbb{R}^{m \times n}$), $\mathbf{X} \in \mathcal{X}$ – параметры модели, $N \geq 1$ – количество узлов, а $f_j(\mathbf{X})$ – функция потерь модели $\mathbf{X}$ на данных $\mathcal{D}_j$, хранящихся на узле $j \in [N] := \{1, \dots, N\}$.

В федеративном сценарии использования алгоритма SignMuon сервер выполняет роль агрегатора, а основная структурная оптимизация происходит на узлах. В начале раунда t каждый узел j копирует глобальную модель. Вместо выполнения локальных шагов изменения параметров, узел вычисляет усреднённый стохастический градиент, накапливая его по n_{steps} мини-батчам локальных данных.

Algorithm 1 Federated SignMuon

Input: Начальная модель $\mathbf{X}_0$, число узлов N , число раундов rounds , число локальных шагов n_{steps} , шаг обучения η_t (для основных слоёв), шаг обучения η_t^{aux} (для последнего слоя), коэффициент момента μ

Output: Обновлённая глобальная модель $\mathbf{X}$

```
1: for  $j = 1$  to  $N$  do
2:    $\mathbf{M}_0^{(j)} \leftarrow \mathbf{0}$  ▷ Инициализация локальных буферов на узлах
3: end for
4: Инициализация AdamW для last_layer с  $\text{lr} = \eta_{\text{aux}}$ 
5: for  $t = 1$  to rounds do
6:   for  $j = 1$  to  $N$  in parallel do
7:      $\mathbf{X}_t^{(j)} \leftarrow \mathbf{X}_t$  ▷ Получение глобальной модели
8:     for  $k = 1$  to  $n_{\text{steps}}$  do
9:       Сэмплировать батч  $\xi_{t,k}^{(j)}$ 
10:       $\nabla f_k \leftarrow \nabla f(\mathbf{X}_t^{(j)}; \xi_{t,k}^{(j)})$ 
11:       $\mathbf{G}_t^{(j)} \leftarrow \mathbf{G}_t^{(j)} + \nabla f_k$ 
12:    end for
13:
14:     $\mathbf{G}_t^{(j)} \leftarrow \mathbf{G}_t^{(j)} / n_{\text{steps}}$  ▷ Усреднение градиентов
15:     $\mathbf{M}_t^{(j)} \leftarrow \mu \mathbf{M}_{t-1}^{(j)} + \mathbf{G}_t^{(j)}$  ▷ Обновление локального момента
16:     $\mathbf{Y}_t^{(j)} \leftarrow \text{ReshapeTo2D}(\mathbf{M}_t^{(j)})$  ▷ Приведение момента к матрице  $m \times n$ 
17:    for  $k = 1$  to  $n_{\text{steps}}$  do ▷ Ортогонализация (Muon LMO)
18:       $\mathbf{A}_t^{(j)} \leftarrow \mathbf{Y}_t^{(j)} (\mathbf{Y}_t^{(j)})^T$ 
19:       $\mathbf{Y}_t^{(j)} \leftarrow a \mathbf{Y}_t^{(j)} - b \mathbf{A}_t^{(j)} \mathbf{Y}_t^{(j)} + c (\mathbf{A}_t^{(j)})^2 \mathbf{Y}_t^{(j)}$ 
20:    end for
21:     $\mathbf{D}_t^{(j)} \leftarrow \text{ReshapeToOriginal}(\mathbf{Y}_t^{(j)})$ 
22:     $\mathbf{s}_t^{(j)} \leftarrow \text{sign}(\mathbf{D}_t^{(j)})$  ▷ Знаковая компрессия
23:    Отправить  $\mathbf{s}_t^{(j)}$  на сервер
24:  end for
25:   $\mathbf{s}_t^{\text{agg}} \leftarrow \text{sign}\left(\sum_{j=1}^N \mathbf{s}_t^{(j)}\right)$  ▷ Majority-vote агрегация на сервере
26:
27:   $\mathbf{X}_{t+1} \leftarrow \mathbf{X}_t - \eta_t \mathbf{s}_t^{\text{agg}}$  ▷ Обновление матричных параметров
28:
29:   $\mathbf{X}_{t+1}^{\text{last}} \leftarrow \text{AdamW}(\mathbf{X}_t^{\text{last}}, \mathbf{s}_t^{\text{agg}}, \eta_t^{\text{aux}})$  ▷ Обновление последнего слоя
30: end for
31: return  $\mathbf{X}_{\text{rounds}}$ 
```

Эксперименты и Результаты

Минимизация гладкой выпуклой функции:

$$F(\mathbf{X}) = \frac{1}{2} \|\mathbf{M}^{1/2} \mathbf{X} \mathbf{N}^{1/2}\|_F^2 = \frac{1}{2} \langle \mathbf{X}, \mathbf{M} \mathbf{X} \mathbf{N} \rangle \rightarrow \min_{\mathbf{X} \in \mathbb{R}^{m \times n}}, \quad (4)$$

где $\mathbf{X} \in \mathbb{R}^{m \times n}$ ($m = n = 500$), $\mathbf{M} \in \mathbb{S}_+^m$ и $\mathbf{N} \in \mathbb{S}_+^n$.




Figure 1. Сравнение оптимизаторов на гладкой выпуклой задаче (уравнение 4). Показано наименьшее число итераций, обеспечивающее достижение $F(\mathbf{X}) \leq 0.001$.

Централизованное обучение:

Dataset	Optimizer	Epoch	Batch	LR	LR Aux	Mom	Train Acc	Test Acc
CIFAR-10	SignMuon	50	128	0.015	0.001	0.9	93.81%	88.05%
	Muon			0.015			94.56%	87.16%
	Adam			0.001			92.08%	86.67%
	SGD			0.015			91.07%	85.72%
	SignSGD			0.001			85.57%	84.24%





Figure 2. Централизованный сценарий. Сравнение сходимости и точности классификации на CIFAR-10 для двухслойной сверточной нейронной сети при использовании различных оптимизаторов.

Федеративное обучение: Зависимость от числа узлов

Table 1. Итоговая точность SignMuon после 2000 раундов

Число узлов	1	3	5	7	9
Точность (Accuracy)	76.13%	81.24%	82.87%	83.54%	84.03%



Федеративное обучение: Сравнение алгоритмов ($N = 3, n_{\text{steps}} = 1$) и ($N = 10, n_{\text{steps}} = 3$)




Figure 4. Федеративное обучение. Сравнение разных алгоритмов при $N = 3, n_{\text{steps}} = 1$.




Figure 5. Федеративное обучение. Сравнение разных алгоритмов при $N = 10, n_{\text{steps}} = 3$.

Основные источники

- J. Bernstein et al. *signSGD: Compressed Optimisation for Non-Convex Problems*. International Conference on Machine Learning, 2018.
- J. Bernstein et al. *signSGD with Majority Vote is Communication Efficient And Fault Tolerant*. International Conference on Learning Representations, 2019.
- A. Beznosikov et al. *On Biased Compression for Distributed Learning*. Journal of Machine Learning Research, 2023.
- T. Pethick et al. *Training Deep Learning Models with Norm-Constrained LMOs*. International Conference on Machine Learning, 2025.